

Biologia Quantitativa 2023/01

Módulo 01

Introdução ao Curso Lógica de Análise de Dados

Depto de Zoologia
28 de março de 2023

Usos da Estatística em Biologia

- Visualização e Descrição dos Dados
- Transformar idéias em hipóteses testáveis
- Testes de Hipóteses e comparação de amostras
- Testes de Hipóteses e ajuste de modelos
- Modelagem e construção de cenários no tempo e no espaço além do universo amostral disponível

Expectativas do Semestre

- Conhecimento básico dos métodos descritivos, tipos de variáveis, R, QGIS
- Conhecimento de testes de hipóteses por comparações de amostras, capacidade de compreender abordagens nos artigos científicos, o que são distribuições
- Ajustes por mínimos quadrados e modelos lineares e linearizados. Regressão e Análise de Variância.
- Análise de dados espaciais, interpretação de imagens de satélites
- Métodos avançados para modelar a natureza: redes neurais, algoritmos genéticos, autômatos celulares

Abordagem do Curso

- Foco na discussão de dados biológicos e estatística: idéias, coleta de dados, testes de hipóteses, métodos de análise
- Quatro seções conceituais:
- Seção 1: coleta, visualização e descrição de dados por métodos gráficos e quantitativos (estatística descritiva)
- Seção 2: comparações de amostras e populações, testes de hipóteses, estatística frequencista
- Seção 3: ajustes de modelos por métodos estatísticos - Análise de variância, regressão, mínimos quadrados, máxima verossimilhança, random forest, splines
- Seção 4: análises multivariadas para redução de variáveis, ordenação, classificação geração de cenários, modelagem por inteligência artificial

Lógica de Análise de Dados

- Em nossas aulas discutiremos o uso de análises estatísticas, incluindo a caracterização de distribuições e testes de hipóteses sobre tais características
- Primeiro devemos selecionar os dados que nos interessam como indicadores de parâmetros biológicos.
- Em seguida usamos a estatística para descrever as distribuições de dados e testar hipóteses a respeito das distribuições.
- Finalmente usamos os resultados dos testes estatísticos para fazer inferências sobre os processos biológicos dos quais os dados originais foram gerados
- Ref para hoje: Andrade e Ogari cap. 2

Tipos de dados para análises

- **Nominal, Categóricos** - valores não ordenados (classes)
- **Ordinal** - valores ordenados sem quantificar as diferenças permite teste de ranking, scores
- **Intervalo** - variáveis contínuas, permite analisar variâncias, erro
- **Razão** - valor zero é referência absoluta não arbitrária
- **Frequências** - contagens (mesmos métodos dos categóricos)

Exemplos de dados em biologia

- Nominal - atributo ex nome de espécie
- Ordinal - reflete ordenação, ranking. Exemplo: ordem de preferência das presas por um predador
- Intervalo - dados numéricos com intervalos contínuos e equivalentes. Exemplo: temperatura fahrenheit, celsius. Zero é um valor convencional, não é absoluto.
- Razão - dados numéricos em que a origem (zero) tem valor absoluto: exemplo temperatura kelvin (zero grau), tempo
- Quantitativas discretas (números inteiros)

Sistemas Complexos

(Claudia Pahl-Wostl 1995)

- Extrapolações lineares não são factíveis
- Prever os limites e transições é extremamente difícil
- Fatores relevantes são difíceis de reconhecer devido à sua pequena importância em situações estáveis.
- Relações causa-efeito quase inexistentes. Efeitos dependem do estado atual e do contexto.
- Exemplos: dinâmica de ecossistemas, queimadas, espécies invasoras, sociedades humanas
- Métodos: universos digitais no computador. A vida biológica é digital (4 bases)

Sistemas Complexos

- Apresentam características de auto-organização
- Existem no limite do caos
- Não são previsíveis individualmente, mas seu comportamento segue regras gerais.
- Como estudar? por métodos estatísticos e por modelagem. Embora a trajetória individual do sistema não seja previsível, o conjunto de trajetórias tem limites (atratores)
- Nas sociedades humanas, os sistemas complexos são estudados por meio de análise histórica. É possível demonstrar o encadeamento de variáveis que produziu o resultado observado, a posteriori.

Sistemas Complexos

- Há estabilidade em sistemas complexos?
- Como diferem de comportamento caótico?
- Estudos de simulação mostram resultados interessantes. Exemplo: redes de interação em ecossistemas.
- Se há interações fortes entre todos os componentes do ecossistema, e feedbacks positivos, o sistema é instável
- Em sistemas que tendem à estabilidade, ao longo do tempo, as interações fortes se restringem a um número pequeno de componentes (espécies dominantes) e a mediação se dá principalmente por retroalimentação negativa (feedback negativo).

Sistemas Complexos

- A escolha das medidas é fundamental para entender os processos que ocorrem.
- Por exemplo, uma medida ordinal dá uma idéia da ordem de importância, mas não explicita as magnitudes das diferenças entre os componentes do sistema.
- Já as medidas de intervalo ou razão permitem posicionar melhor a situação de cada componente
- Uma escola de samba é um exemplo ótimo de um sistema complexo (veja as definições anteriores)
- Vamos ver como os resultados variam de ano para ano. E como o uso de medidas de intervalo permite compreender o fenômeno muito melhor do que usando medidas ordinais.

Exemplos Dados Ordinal Intervalo

Classif Escolas de Samba Rio 2017

- 1 Portela
- 2 Mocidade
- 3 Salgueiro
- 4 Mangueira
- 5 Grande Rio
- 6 Beija Flor
- 7 Imperatriz
- 8 União da Ilha
- 9 São Clemente
- 10 Vila Isabel



Creative Commons / Ben Tavener

Exemplos Dados Ordinal Intervalo

Escolas de Samba Rio 2017 2018

● 1 Portela	269,9	269,4	4
● 2 Mocidade	269,8	269,3	6
● 3 Salgueiro	269,7	269,5	3
● 4 Mangueira	269,6	269,3	5
● 5 Grande Rio	269,4	266,8	rebaix
● 6 Beija Flor	269,2	269,6	1
● 7 Imperatriz	268,5	268,8	8
● 8 União da Ilha	267,8	267,3	10
● 9 São Clemente	267,4	266,9	11
● 10 Vila Isabel	267,4	268,1	9

Fenômeno de Regressão à Média

- Resultados extremos não são replicáveis consistentemente em grupos coesos se forem resultados de alta complexidade e muitas variáveis
- Times esportivos
- Grupos artísticos
- Grupos políticos
- Indivíduos nestes sistemas
- A tendência é a volta à média depois de resultados extremos (positivos ou negativos)
- Determinados tipos de variáveis como ordenação ou percentagens não informam os dados

Análise exploratória de dados


- Faremos exercício prático no R
- Elementos essenciais: gráficos de distribuição, dispersão, classificação, tendência central, estimativa e erro de estimativa, variância
- Métodos geralmente adotados:
- Gráficos contínuos ou por classes
- Tabelas de Frequências
- Medidas de tendência central: média, moda, mediana
- Variância, desvio padrão da amostra, coeficiente de variação
- Índices de associação (correlação de pearson), regressão

Estatísticas descritivas úteis

- Matriz de dados
- Mediana (divide distribuição em duas)
- Quartis - dividem a distribuição em quartos
- Moda (frequência ou valor mais abundante)
- Variância e desvio padrão (medida de dispersão da pop)
- Erro padrão da média (medida de dispersão na estimativas da média)
- Intervalo de confiança - intervalo que cobre x% da distribuição

Estatísticas descritivas úteis

- Média, moda, mediana



Exemplo de Pesquisa Moderna

- Trabalho na Serra da Mesa, Goiás. Laboratório Prof Reuber, UnB/EFL.



Lizards on newly created islands independently and rapidly adapt in morphology and diet

Mariana Eloy de Amorim^{a,b,1}, Thomas W. Schoener^{b,1}, Guilherme Ramalho Chagas Cataldi Santoro^c, Anna Carolina Ramalho Lins^a, Jonah Piovia-Scott^d, and Reuber Albuquerque Brandão^a

^aLaboratório de Fauna e Unidades de Conservação, Departamento de Engenharia Florestal, Universidade de Brasília, Brasília DF, Brazil CEP 70910-900;

^bEvolution and Ecology Department, University of California, Davis, CA 95616; ^cDepartamento de Pós-Graduação em Zoologia, Instituto de Biologia, Universidade de Brasília, Brasília DF, Brazil CEP 70910-900; and ^dSchool of Biological Sciences, Washington State University, Vancouver, WA 98686-9600

Contributed by Thomas W. Schoener, June 21, 2017 (sent for review December 31, 2016; reviewed by Raymond B. Huey and Dolph Schluter)

Rapid adaptive changes can result from the drastic alterations humans impose on ecosystems. For example, flooding large areas for hydroelectric dams converts mountaintops into islands and leaves surviving populations in a new environment. We report differences in morphology and diet of the termite-eating gecko *Gymnodactylus amarali* between five such newly created islands

study, because it was the most common lizard species in the area at the time of the field study.

We evaluated the effects of isolation (actually, insularization) on diet and morphology of *G. amarali* populations on islands formed by the Serra da Mesa reservoir. We collected data on lizard diet and morphology on five islands, as well as five nearby



Data from: Lizards on newly created islands independently and rapidly adapt in morphology and diet

Eloy de Amorim M, Schoener TW, Santoro GRCC, Lins ACR, Piovita-Scott J, Brandão RA

Date Published: August 10, 2017

DOI: <https://doi.org/10.5061/dryad.3nk78>

[Submit data now](#)

[How and why?](#)

Search for data

Enter keyword, DOI, etc.

[Go](#)

[Advanced search](#)

Files in this package

Content in the Dryad Digital Repository is offered "as is." By downloading files, you agree to the [Dryad Terms of Service](#). To the extent possible under law, the authors have waived all copyright and related or neighboring rights to this data.  

Title	Data used for analysis of niche breadth
Downloaded	21 times
Description	Data are from <i>Gymnodactylus amarali</i> individuals collected from field sites near the Serra da Mesa Reservoir in central Brazil. The following column headings are used. area: Each field site was either an island created by the filling of the reservoir or part of the adjacent mainland site: a unique identifier for each field site lizard: a unique identifier for each lizard captured as part of the study termite.length_mm: the length of individual termites (in millimeters) found in the stomach of lizards used in the study
Download	NicheBreadth.csv (15.28 Kb)
Details	View File Details

Be part of Dryad

We encourage organizations to:

[Become a member](#)

[Sponsor data publishing fees](#)

[Integrate your journal\(s\)](#), or

All of the above

O que é o R

- Linguagem computacional de alto nível voltada para manipulação e análise de dados
- Versão de código livre e aberto da linguagem S
- Desenvolvida por consórcio global de pessoas e organizações (R Project)
- A linguagem base é suplementada e estendida por “pacotes” com rotinas, funções e dados voltados para disciplinas e aplicações específicas.
- Linguagem interpretada, não compilada, portanto tem restrições de tamanho de conjunto de dados e velocidade de computação.

As 4 abordagens para usar R

- Importar e organizar dados e objetos
- Funções e operações
- Visualização e descrição de dados
- Ajuste de modelos e análises estatísticas

Colocando dados no R

- Manual usando comandos R e arquivos de texto ou clipboard
- Usando menu do Rstudio
- Carregando pacotes contendo conjuntos de dados
- Executando scripts do R para local ou internet

Pacotes no R

- Os pacotes em R são elementos de programação executáveis que contém rotinas pré-escritas, permitindo:
- Utilizar funções desenvolvidas para aplicações específicas
- Executar análises, plotar gráficos, etc, em formatos e para necessidades personalizadas
- Integrar vários produtos da linguagem R em um arquivo único: dados, funções, variáveis, rotinas
- Minimizar o trabalho de executar trabalhos repetidos
- Distribuir métodos analíticos de forma confiável e replicável

O que é o Rstudio

- Interface Gráfica para a linguagem R
- Cada janela permite um tipo de acesso à linguagem
- 4 janelas básicas:
 - Script ou markdown ou notebook
 - Comando
 - Saída/ajuda
 - Variáveis de estado
- Versões windows, mac, linux, servidor, cloud
- Software gratuito para uso individual, pago na versão empresarial
- Modelo comercial / apoio comunitário

Como funciona o Rstudio

- Oferece janelas para visualizar ao mesmo tempo diversas interfaces do R
- Sem as janelas o usuário teria só uma forma de visualização: a linha de comando
- Uma das janelas é a linha de comando
- Uma janela permite editar e executar os scripts, markdown ou notebooks (o R é uma linguagem interpretada, opera linha por linha, o script é só uma sequência de comandos)
- Uma janela permite administrar pacotes, acessar o help, visualizar saídas gráficas, e outros
- Uma janela mostra as variáveis em uso
- Menu do Rstudio permite executar alguns comandos sem ter de digitar por extenso

Softwares Estatísticos Conhecidos

- R
- Systat, SPSS, SAS, MVSP
- Bioestat - Ayres (gratuito, distribuído pela Soc Civ Mamirauá)
- Vários sites de análise online
- Cuidado: cada software usa um algoritmo próprio para implementar análises, podendo estar sujeitos a erros de aproximação ou “bugs”. Verificar a documentação e notícias na internet.
- É importante padronizar a análise para permitir replicação. Procure publicar seus dados originais junto com os artigos, e use programas de amplo uso quando possível